IPC_analysis_LOG

January 13, 2025

[32]:
```
# Importar bibliotecas necesarias para gráficos, manipulación de datos y␣
↪análisis de series temporales
from matplotlib import pyplot as plt
import numpy as np
import pandas as pd
from statsmodels.graphics.tsaplots import plot_acf, plot_pacf  # Para gráficas␣
↪de ACF y PACF
import statsmodels.tsa.stattools as st  # Herramientas estadísticas para series␣
↪temporales

# Variable para alternar entre datos artificiales y datos reales
test_with_artificial = False

# Función para generar datos sintéticos siguiendo un modelo ARIMA
def artificial_arima(p=np.array([]), d=0, q=np.array([]), f=lambda x: x, n=100,␣
↪m=0):
    """
    Genera datos sintéticos basados en un modelo ARIMA para validar el método␣
↪en datos reales.

    Parámetros:
    - p: Coeficientes del modelo AR (Autoregresivo).
    - d: Número de diferencias acumulativas para hacer la serie estacionaria.
    - q: Coeficientes del modelo MA (Media Móvil).
    - f: Función de transformación aplicada a los datos generados.
    - n: Número de puntos en la serie temporal.
    - m: Media del ruido blanco agregado.

    Retorna:
    - Serie transformada basada en los parámetros proporcionados.
    """
    a = np.random.normal(0, 1, n)  # Generar ruido blanco con media 0 y␣
↪varianza 1
    W = np.zeros(n)  # Inicializar la serie temporal

    for t in range(n):
        if t < len(p) or t < len(q):  # Manejar índices fuera de rango
```

```python
            W[t] = 0
        else:
            # Aplicar componentes AR y MA usando productos escalares
            W[t] = -W[t-len(p):t] @ p[::-1] + a[t] + a[t-len(q):t] @ q[::-1]

    for d_c in range(d):  # Aplicar diferenciación acumulativa d veces
        W = np.cumsum(W)

    W += m  # Agregar media a la serie
    return f(W)  # Aplicar la transformación final

# Si se activa `test_with_artificial`, generar datos sintéticos
if test_with_artificial:
    n = 1000  # Número de puntos en la serie sintética
    points = artificial_arima(
        p=np.array([0]),  # Coeficientes AR
        q=np.array([0]),  # Coeficientes MA
        d=0,  # Diferenciación
        f=np.exp,  # Función de transformación exponencial
        n=n,  # Tamaño de la serie
        m=0  # Media
    )
    # Crear un DataFrame con los datos generados y el índice temporal
    time_series_df = pd.DataFrame({'points': points})
else:
    # Usar un dataset real: WWWusage

    time_series_df = pd.read_csv('../data/IPC.csv')

    # Convert the second column to float
    time_series_df = time_series_df.astype({"IPC": float})
    time_series_df["points"] = time_series_df["IPC"]


    print(time_series_df)

# Función para graficar una serie temporal, su ACF y PACF
def plot_series(series, series_title, alpha=0.05):
    """
    Grafica una serie temporal junto con sus funciones ACF y PACF.

    Parámetros:
    - series: Serie temporal a graficar.
    - series_title: Título para la gráfica de la serie temporal.
    - alpha: Nivel de significancia para los intervalos de confianza en ACF y␣
 ↪PACF.
    """
```

```
    fig = plt.figure(figsize=(8, 6.5))  # Crear figura de tamaño personalizado
    gs = fig.add_gridspec(2, 2)  # Crear un diseño de 2 filas y 2 columnas

    # Gráfica de la serie temporal
    ax0 = fig.add_subplot(gs[0, :])  # Primera fila ocupa ambas columnas
    ax0.plot(series)
    ax0.set_title(series_title)
    ax0.set_ylabel('Accesos al servidor')

    # Gráfica de ACF
    ax1 = fig.add_subplot(gs[1, 0])  # Segunda fila, primera columna
    plot_acf(series, ax=ax1, alpha=alpha)
    ax1.set_title("ACF")

    # Gráfica de PACF
    ax2 = fig.add_subplot(gs[1, 1])  # Segunda fila, segunda columna
    plot_pacf(series, ax=ax2, alpha=alpha)
    ax2.set_title("PACF")

    plt.tight_layout()  # Ajustar diseño
    plt.show()  # Mostrar gráficos

# Graficar la serie temporal con su ACF y PACF
plot_series(time_series_df['points'], "Datos Originales")
```

```
       IPC  points
0   30.210  30.210
1   30.321  30.321
2   30.349  30.349
3   30.430  30.430
4   30.433  30.433
..     …       …
87  62.939  62.939
88  63.380  63.380
89  63.633  63.633
90  64.170  64.170
91  64.787  64.787

[92 rows x 2 columns]
```

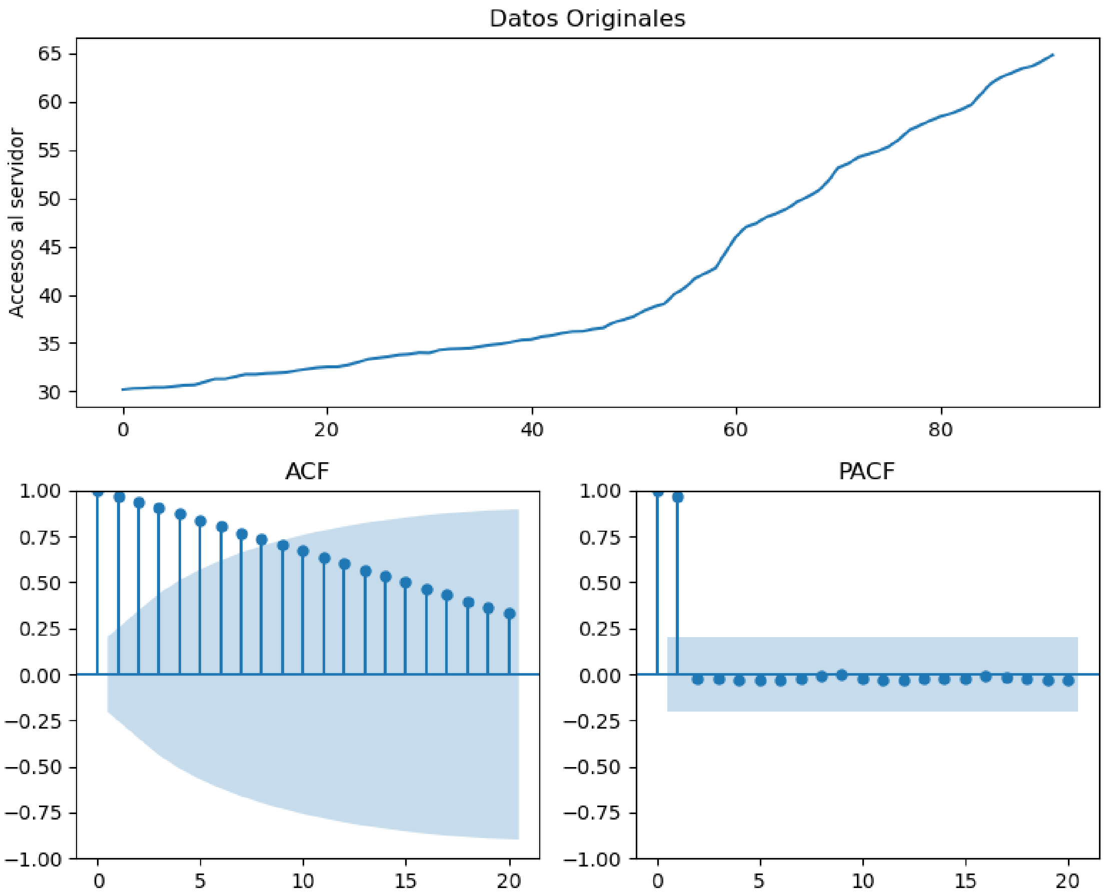

Utiliza un método completamente automático de biblioteca para determinar el modelo ARIMA que maximice la precisión, de modo que podamos comparar el resultado de nuestro método con el resultado de este método.

[18]:
```
if False:  # Cambia a `True` para ejecutar este bloque de código
    import pmdarima as pm  # Biblioteca para ajuste automático de modelos ARIMA/
 ↪SARIMA

    # Ajustar automáticamente el mejor modelo ARIMA/SARIMA
    model = pm.auto_arima(
        time_series_df['points'],  # Columna de datos de la serie temporal
        seasonal=False,            # Desactiva el componente estacional
        stepwise=False,            # Desactiva el algoritmo de búsqueda paso a␣
 ↪paso (más exhaustivo)
        trace=True,                # Muestra detalles del proceso de ajuste
        max_p=3,                   # Máximo valor de p (orden autoregresivo)
        max_q=3,                   # Máximo valor de q (orden de media móvil)
        max_d=2,                   # Máximo número de diferenciaciones (d)
```

```
        start_d=2,                  # Comienza probando con una diferenciación␣
↪inicial d=2
        test='adf',                 # Prueba de Dickey-Fuller para verificar␣
↪estacionariedad
        max_order=10                # Límite máximo para p + q + P + Q
    )

    # Mostrar un resumen del mejor modelo ajustado
    print(model.summary())

    # Pronosticar valores futuros (por ejemplo, para los próximos 12 períodos)
    forecast = model.predict(n_periods=12)  # Genera predicciones para 12␣
↪períodos futuros
```

Prueba la estacionariedad utilizando el test de raíz unitaria de Dickey-Fuller aumentado.

[19]:
```
# Verificar la estacionariedad de la serie temporal
# La hipótesis alternativa de la prueba ADF es que la serie es estacionaria
st.adfuller(time_series_df['points'])  # Realizar la prueba ADF
```

[19]:
```
(2.54902325412832,
 0.9990639726819293,
 1,
 90,
 {'1%': -3.505190196159122,
  '5%': -2.894232085048011,
  '10%': -2.5842101234567902},
 20.0058424285088)
```

p value > 0.05 => no stationaridad

Aplica la transformación de Box-Cox y usa scipy para estimar el parámetro óptimo de Box-Cox, lambda.

Decidimos no utilizar esta transformación, ya que después de diferenciar los datos, la serie temporal parece bastante estable. Además, obtuvimos mejores resultados al no aplicar ninguna transformación.

[20]:
```
from scipy import stats  # Importar herramientas estadísticas de SciPy

# Variable para controlar si se aplica la transformación Box-Cox
use_trafo = True

# Verificar si se aplica la transformación Box-Cox
if use_trafo:
    # Aplicar la transformación Box-Cox y estimar lambda automáticamente si no␣
↪se especifica
    lmbda = 0  # Valor inicial de lambda; si es None, se estima automáticamente
    if lmbda is None:
```

```
        # Aplicar Box-Cox y estimar lambda óptimo
        transformed_prices, lmbda = stats.boxcox(time_series_df["points"])
    else:
        # Aplicar Box-Cox con un valor específico de lambda
        transformed_prices = stats.boxcox(time_series_df["points"], lmbda=lmbda)

    # Almacenar los valores transformados en el DataFrame
    time_series_df['T_points'] = transformed_prices
    print("Lambda usado: ", lmbda)  # Mostrar el valor de lambda utilizado
else:
    # Si no se aplica la transformación, conservar la serie original
    lmbda = None
    time_series_df['T_points'] = time_series_df['points']

# Graficar la serie temporal (transformada o sin transformar)
plot_series(time_series_df['T_points'], f"Serie Temporal Transformada con␣
 ↪Box-Cox (lambda={lmbda})")
```

```
Lambda usado:  0
```

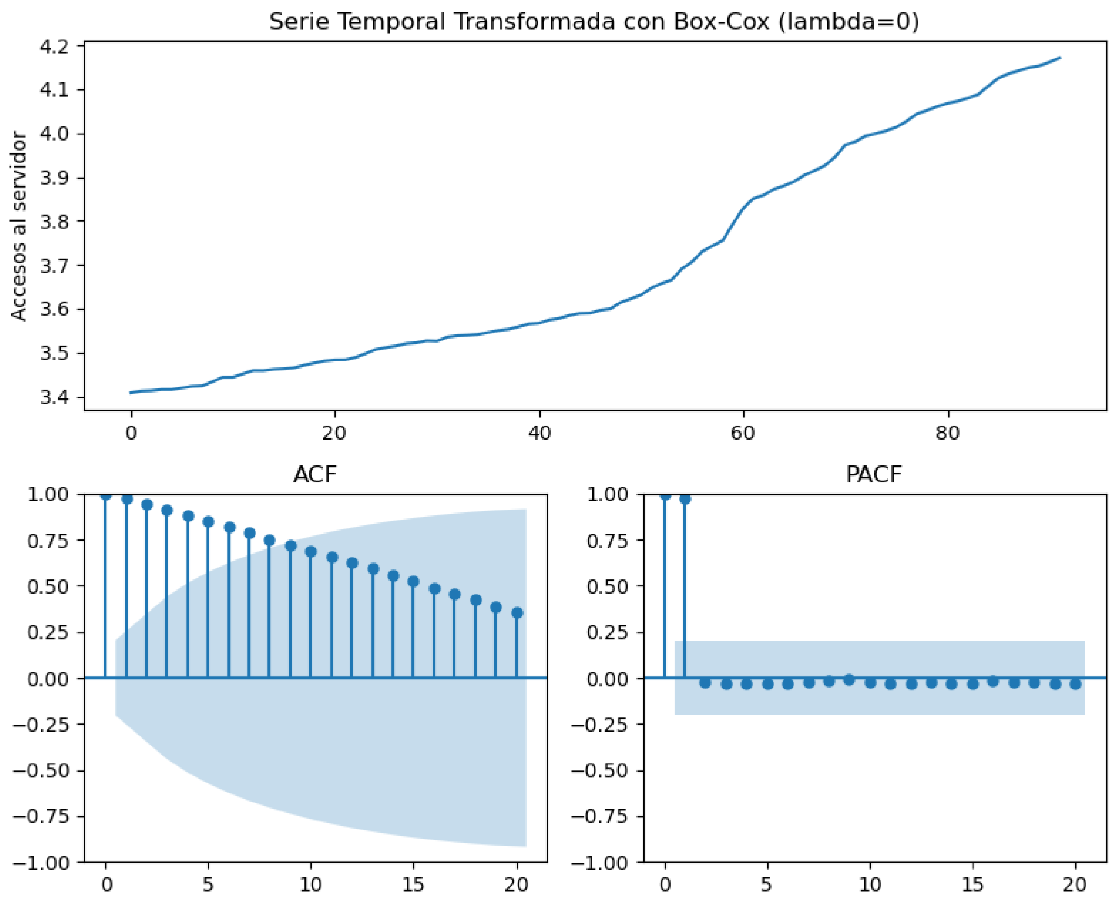

Diferencia los datos hasta que las pruebas de estacionariedad sean positivas.

```
[21]: from statsmodels.sandbox.archive import tsa  # Importar herramientas para␣
      ↪análisis de series temporales (opcional)

      # Nivel de significancia para la prueba ADF
      alpha = 1e-8#0.05

      # Seleccionar la serie transformada sin valores nulos
      current_series = time_series_df['T_points'].dropna()
      d = 0  # Contador de diferenciaciones aplicadas

      # Función para obtener el p-valor de la prueba ADF
      def get_adf_p_value(series):
          """
          Realiza la prueba Dickey-Fuller Aumentada (ADF) y retorna el p-valor.

          Parámetros:
          - series: Serie temporal a analizar.

          Retorna:
          - p-valor de la prueba ADF.
          """
          adf_result = st.adfuller(series.dropna())  # Realizar la prueba ADF
          return adf_result[1]  # Retornar el p-valor

      # Iterar hasta que la serie sea estacionaria o se alcance el máximo de␣
      ↪diferenciaciones
      while get_adf_p_value(current_series) >= alpha:
          d += 1  # Incrementar el contador de diferenciaciones
          # Aplicar diferenciación de primer orden
          current_series = current_series.diff()  # Calcula la diferencia entre␣
      ↪valores consecutivos

          # Imprimir el progreso y el p-valor después de cada diferenciación
          print(f"Después de {d} diferenciación(es), el p-valor de ADF es:␣
      ↪{get_adf_p_value(current_series)}")

      # Agregar la serie diferenciada al DataFrame original
      time_series_df['diff_points'] = current_series.copy()

      # Verificar si la serie es estacionaria después de la diferenciación
      if get_adf_p_value(current_series) < alpha:
          print(f"La serie es estacionaria después de {d} diferenciación(es).")
      else:
          print("Se alcanzó el máximo de diferenciaciones sin lograr estacionariedad.
      ↪")
```

```
Después de 1 diferenciación(es), el p-valor de ADF es: 9.494358947328384e-05
Después de 2 diferenciación(es), el p-valor de ADF es: 2.74331046287607e-11
La serie es estacionaria después de 2 diferenciación(es).
```

Grafica la nueva serie temporal y las funciones de ACF y PCF.

[22]:
```
# Seleccionar la serie diferenciada eliminando valores nulos generados por la␣
↪operación diff
data = time_series_df['diff_points'].dropna()

# Graficar la serie diferenciada junto con las gráficas de ACF y PACF
plot_series(data, f"Datos Diferenciados (d={d})", alpha=0.05)
```

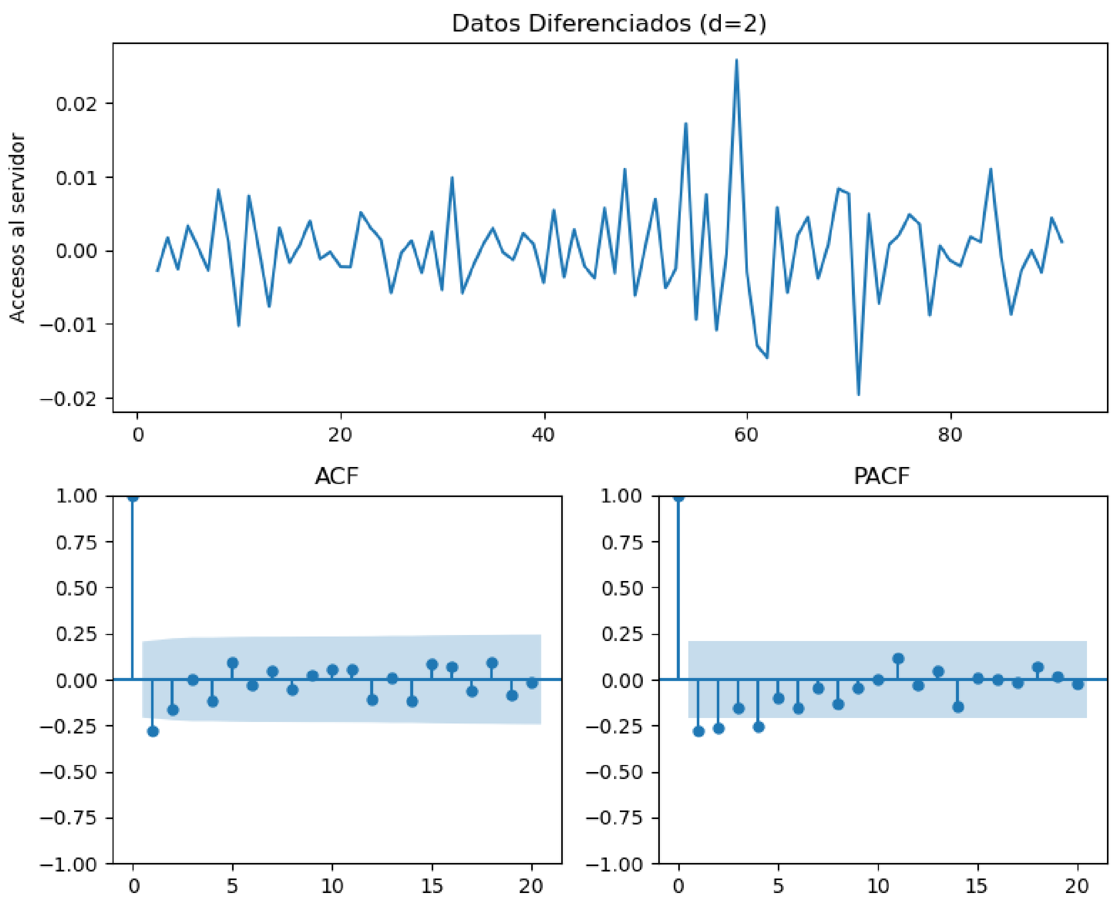

Imprime todos los rezagos que son significativamente diferentes de cero.

[23]:
```
data = time_series_df['T_points'].dropna()

def print_significant_lags(data, alpha=0.05, nlags=26):
    """
    Calculate and print all significantly non-zero lags using ACF.
```

```
    Parameters:
    -----------
    data : array-like
        The time series data
    alpha : float, default=0.05
        Significance level for the confidence intervals
    nlags : int, default=40
        Number of lags to calculate

    Returns:
    --------
    tuple
        - List of significant lag indices
        - ACF values for significant lags
        - Confidence intervals
    """
    # Calculate ACF with confidence intervals
    acf_values, acf_confint = st.acf(data, alpha=alpha, fft=True, nlags=nlags,␣
↪adjusted=True)
    pacf_values, pacf_confint = st.pacf(data, alpha=alpha, nlags=nlags)

    # The confidence intervals come as [lower, upper] for each lag
    # If 0 is not in [lower, upper], the lag is significant
    acf_significant_lags = []
    acf_significant_values = []

    print(f"\nSignificant lags at {alpha*100}% significance level:")
    print("----------------------------------------")
    print("Lag | ACF Value | Confidence Interval")
    print("----------------------------------------")

    for lag in range(len(acf_values)):
        lower_ci = acf_confint[lag][0]
        upper_ci = acf_confint[lag][1]

        # Check if 0 is outside the confidence interval
        if (lower_ci > 0) or (upper_ci < 0):
            acf_significant_lags.append(lag)
            acf_significant_values.append(acf_values[lag])
            print(f"{lag:3d} | {acf_values[lag]:9.3f} | [{lower_ci:6.3f},␣
↪{upper_ci:6.3f}]")


    # The confidence intervals come as [lower, upper] for each lag
    # If 0 is not in [lower, upper], the lag is significant
    pacf_significant_lags = []
```

```python
    pacf_significant_values = []

    print(f"\nSignificant lags at {alpha*100}% significance level:")
    print("----------------------------------------")
    print("Lag | PACF Value | Confidence Interval")
    print("----------------------------------------")

    for lag in range(len(pacf_values)):
        lower_ci = pacf_confint[lag][0]
        upper_ci = pacf_confint[lag][1]

        # Check if 0 is outside the confidence interval
        if (lower_ci > 0) or (upper_ci < 0):
            pacf_significant_lags.append(lag)
            pacf_significant_values.append(acf_values[lag])
            print(f"{lag:3d} | {pacf_values[lag]:10.3f} | [{lower_ci:6.3f},␣
↪{upper_ci:6.3f}]")


    if not acf_significant_lags and not pacf_significant_lags:
        print("No significant lags found.")

    return (acf_significant_lags, acf_significant_values, acf_confint),␣
↪(pacf_significant_lags, pacf_significant_values, pacf_confint)
sig = print_significant_lags(data)
```

```
Significant lags at 5.0% significance level:
----------------------------------------
Lag | ACF Value | Confidence Interval
----------------------------------------
  0 |     1.000 | [ 1.000,  1.000]
  1 |     0.982 | [ 0.778,  1.187]
  2 |     0.964 | [ 0.614,  1.314]
  3 |     0.944 | [ 0.497,  1.391]
  4 |     0.923 | [ 0.399,  1.447]
  5 |     0.900 | [ 0.312,  1.488]
  6 |     0.876 | [ 0.234,  1.519]
  7 |     0.851 | [ 0.161,  1.542]
  8 |     0.826 | [ 0.093,  1.559]
  9 |     0.801 | [ 0.030,  1.572]

Significant lags at 5.0% significance level:
----------------------------------------
Lag | PACF Value | Confidence Interval
----------------------------------------
  0 |      1.000 | [ 1.000,  1.000]
```

```
 1 |      0.982 | [ 0.778,  1.187]
```

0.1 Estimate Parameters

[24]:
```python
from statsmodels.tsa.arima.model import ARIMA  # Importar el modelo ARIMA

# Seleccionar la serie transformada y eliminar valores nulos
data = time_series_df['T_points'].dropna()

# Definir los modelos ARIMA sugeridos
suggested_models = np.array([
    [0, d, 0],
    [0, d, 2],  # Modelo ARIMA(0,d,2)
])

# Inicializar listas para almacenar resultados y modelos ajustados
results = []  # Lista para almacenar métricas de ajuste (AIC, BIC)
error_dfs = []  # Lista para almacenar los residuales de cada modelo
fitted_models = []  # Lista para almacenar los modelos ajustados

# Iterar sobre los modelos sugeridos y ajustar cada uno
for p, d, q in suggested_models:
    # Ajustar el modelo ARIMA con los parámetros actuales (p, d, q)
    model = ARIMA(data, order=(p, d, q))
    fitted = model.fit()

    # Guardar las métricas de rendimiento (AIC y BIC)
    results.append({
        'order': f"ARIMA({p},{d},{q})",
        'aic': fitted.aic,
        'bic': fitted.bic,
        'p': p,
        'd': d,
        'q': q
    })

    # Imprimir los resultados del modelo
    print(f"\nARIMA({p},{d},{q}):")
    print(f"AIC: {fitted.aic:.2f}")
    print(f"BIC: {fitted.bic:.2f}")

    # Obtener los residuales del modelo ajustado
    residuals = pd.DataFrame(fitted.resid)[p+d+q:]  # Excluir los primeros␣
 ↪valores que dependen de datos iniciales
    residuals.columns = [f'ARIMA({p},{d},{q})']  # Etiquetar los residuales con␣
 ↪el nombre del modelo
    error_dfs.append(residuals)
```

```python
    # Almacenar el modelo ajustado
    fitted_models.append(fitted)

# Combinar todos los residuales en un único DataFrame
all_errors = pd.concat(error_dfs, axis=1)

# Crear un DataFrame para los modelos ajustados
fitted_models_df = pd.DataFrame({
    'model_order': [f"ARIMA({p},{d},{q})" for p, d, q in suggested_models],
    'fitted_model': fitted_models
})

# Graficar los residuales de los modelos ajustados
plt.figure(figsize=(12, 6))
for column in all_errors.columns:
    plt.plot(all_errors.index, all_errors[column], label=column, alpha=0.7)
plt.legend()
plt.title('Comparación de Residuales entre Modelos ARIMA')
plt.xlabel('Tiempo')
plt.ylabel('Error')
plt.grid(True, alpha=0.3)
plt.show()
```

```
ARIMA(0,2,0):
AIC: -651.81
BIC: -649.31

ARIMA(0,2,2):
AIC: -671.31
BIC: -663.81
```

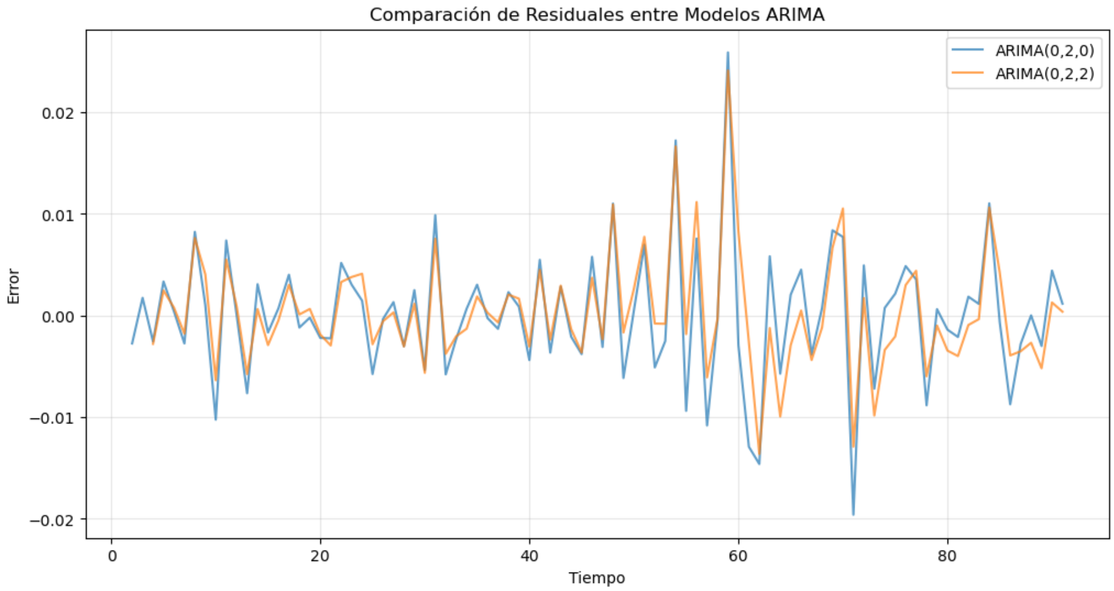

0.2 Verify 8 supuestos

0.2.1 Tests on residuals, Supuestos 1-4

[25]:
```python
import statsmodels.api as sm  # Importar herramientas para modelos estadísticos
from scipy.stats import shapiro, jarque_bera, ttest_1samp  # Pruebas de␣
 ↪normalidad y t-test
from statsmodels.stats.diagnostic import het_breuschpagan, acorr_ljungbox  #␣
 ↪Pruebas de homocedasticidad e independencia

# Inicializar una lista para almacenar los resultados de las pruebas de␣
 ↪residuales
residuals_tests = []

# Función para evaluar los residuales de un modelo
def test_residuals(residuals, model_name, alpha=0.05):
    """
    Realiza pruebas estadísticas en los residuales de un modelo y guarda los␣
 ↪resultados.

    Parámetros:
    -----------
    residuals : array-like
        Residuales del modelo a evaluar.
    model_name : str
        Nombre del modelo para etiquetar los resultados.
    alpha : float, opcional
```

```
        Nivel de significancia para las pruebas (por defecto 0.05).
    """
    results = {}

    # 1. Prueba de media cercana a 0 (t-test)
    p_value = ttest_1samp(residuals, 0).pvalue
    results['mean_close_to_0'] = p_value > alpha  # La media está cerca de 0 si␣
 ↪p-valor > alpha
    print(f"{model_name}: Media de residuales = {np.mean(residuals):.4f},␣
 ↪p-valor = {p_value:.4f}")

    # 2. Prueba de varianza constante (homocedasticidad) usando Breusch-Pagan
    _, pvalue, _, _ = het_breuschpagan(residuals, sm.add_constant(np.
 ↪arange(len(residuals))))
    results['constant_variance'] = pvalue > alpha  # Pasa si p-valor > alpha
    print(f"{model_name}: Homocedasticidad (p-valor de Breusch-Pagan) = {pvalue:
 ↪.4f}")

    # 3. Pruebas de normalidad (Shapiro-Wilk y Jarque-Bera)
    _, shapiro_pvalue = shapiro(residuals)  # Prueba Shapiro-Wilk
    jb_stat, jb_pvalue = jarque_bera(residuals)  # Prueba Jarque-Bera
    results['normal_distribution'] = shapiro_pvalue > alpha and jb_pvalue >␣
 ↪alpha  # Ambas deben pasar
    print(f"{model_name}: Normalidad (p-valor Shapiro-Wilk) = {shapiro_pvalue:.
 ↪4f}")
    print(f"{model_name}: Normalidad (p-valor Jarque-Bera) = {jb_pvalue:.4f}")

    # 4. Prueba de independencia usando Ljung-Box
    lb_test = acorr_ljungbox(residuals, lags=[10], return_df=True)
    pvalue_ljungbox = lb_test['lb_pvalue'].values[0]
    results['independent_errors'] = pvalue_ljungbox > alpha  # Pasa si p-valor␣
 ↪> alpha
    print(f"{model_name}: Independencia (p-valor de Ljung-Box) =␣
 ↪{pvalue_ljungbox:.4f}")

    # Guardar los resultados en la lista
    residuals_tests.append({'model': model_name, 'results': results})

    print("-" * 40)


# Iterar sobre cada columna en el DataFrame `all_errors` (que contiene los␣
 ↪residuales de los modelos)
for column in all_errors.columns:
    print(f"Analizando modelo: {column}")
    residuals = all_errors[column].dropna()  # Eliminar valores NaN si existen
```

```python
    test_residuals(residuals, column)  # Aplicar las pruebas a los residuales


# Resumen de los resultados de las pruebas de residuales
print("\nResumen de las Pruebas de Suposiciones de Residuales:")
for result in residuals_tests:
    model_name = result['model']
    tests = result['results']
    print(f"{model_name}:")
    print(f"  Media cercana a 0: {'Pasa' if tests['mean_close_to_0'] else 'No␣
 ↪pasa'}")
    print(f"  Varianza constante: {'Pasa' if tests['constant_variance'] else␣
 ↪'No pasa'}")
    print(f"  Distribución normal: {'Pasa' if tests['normal_distribution'] else␣
 ↪'No pasa'}")
    print(f"  Errores independientes: {'Pasa' if tests['independent_errors']␣
 ↪else 'No pasa'}")
    print("-" * 40)
```

```
Analizando modelo: ARIMA(0,2,0)
ARIMA(0,2,0): Media de residuales = 0.0001, p-valor = 0.9232
ARIMA(0,2,0): Homocedasticidad (p-valor de Breusch-Pagan) = 0.1622
ARIMA(0,2,0): Normalidad (p-valor Shapiro-Wilk) = 0.0047
ARIMA(0,2,0): Normalidad (p-valor Jarque-Bera) = 0.0000
ARIMA(0,2,0): Independencia (p-valor de Ljung-Box) = 0.2236
----------------------------------------
Analizando modelo: ARIMA(0,2,2)
ARIMA(0,2,2): Media de residuales = 0.0003, p-valor = 0.6577
ARIMA(0,2,2): Homocedasticidad (p-valor de Breusch-Pagan) = 0.1670
ARIMA(0,2,2): Normalidad (p-valor Shapiro-Wilk) = 0.0001
ARIMA(0,2,2): Normalidad (p-valor Jarque-Bera) = 0.0000
ARIMA(0,2,2): Independencia (p-valor de Ljung-Box) = 0.9823
----------------------------------------

Resumen de las Pruebas de Suposiciones de Residuales:
ARIMA(0,2,0):
  Media cercana a 0: Pasa
  Varianza constante: Pasa
  Distribución normal: No pasa
  Errores independientes: Pasa
----------------------------------------
ARIMA(0,2,2):
  Media cercana a 0: Pasa
  Varianza constante: Pasa
  Distribución normal: No pasa
  Errores independientes: Pasa
----------------------------------------
```

0.2.2 Supuesto 5: Modelo Parsimonioso

[26]:
```
# Inicializar listas para almacenar modelos que aprueban o fallan la prueba de␣
↪significancia
models_pass = []  # Modelos cuyos intervalos de confianza NO contienen cero
models_fail = []  # Modelos cuyos intervalos de confianza contienen cero

# Iterar sobre cada modelo ajustado en el DataFrame `fitted_models_df`
for index, row in fitted_models_df.iterrows():
    # Obtener el orden del modelo y el objeto del modelo ajustado
    model_order = row['model_order']
    fitted_model = row['fitted_model']

    # Obtener los intervalos de confianza para los parámetros del modelo
    conf_intervals = fitted_model.conf_int()
    parameters = fitted_model.params  # Obtener los valores estimados de los␣
↪parámetros

    # Imprimir los parámetros del modelo
    print(f"\nParámetros para {model_order}:")
    print(parameters)

    # Imprimir los intervalos de confianza de los parámetros
    print(f"\nIntervalos de Confianza para {model_order}:")
    print(conf_intervals)
    print("-" * 50)

    # Verificar si los intervalos de confianza NO contienen cero
    intervals_do_not_contain_zero = (conf_intervals[0] > 0) |␣
↪(conf_intervals[1] < 0)

    if intervals_do_not_contain_zero.all():
        # Si TODOS los intervalos de confianza no contienen cero
        models_pass.append(model_order)
    else:
        # Si ALGÚN intervalo de confianza contiene cero
        models_fail.append(model_order)

# Imprimir el resumen de resultados
print("\nResumen de Significancia de Parámetros de Modelos ARIMA Basado en␣
↪Intervalos de Confianza:")
print("==================================================")
print("Modelos que Aprobaron (Intervalos de Confianza NO contienen cero):")
print(models_pass)
print("\nModelos que Fallaron (Intervalos de Confianza contienen cero):")
print(models_fail)
```

```
Parámetros para ARIMA(0,2,0):
sigma2    0.000041
dtype: float64

Intervalos de Confianza para ARIMA(0,2,0):
               0         1
sigma2  0.000033  0.000049
--------------------------------------------------

Parámetros para ARIMA(0,2,2):
ma.L1    -0.467194
ma.L2    -0.267091
sigma2    0.000031
dtype: float64

Intervalos de Confianza para ARIMA(0,2,2):
               0         1
ma.L1  -0.665083 -0.269305
ma.L2  -0.456429 -0.077753
sigma2  0.000026  0.000037
--------------------------------------------------

Resumen de Significancia de Parámetros de Modelos ARIMA Basado en Intervalos de
Confianza:
===================================================
Modelos que Aprobaron (Intervalos de Confianza NO contienen cero):
['ARIMA(0,2,0)', 'ARIMA(0,2,2)']

Modelos que Fallaron (Intervalos de Confianza contienen cero):
[]
```

0.2.3 Supuesto 6, modelos crean seria estationario y invertible

[27]:
```
# Inicializar listas para almacenar los modelos que pasan o fallan la prueba de
 ↪estacionariedad
admisible_models = []  # Modelos que cumplen con raíces fuera del círculo
 ↪unitario
non_admisible_models = []  # Modelos que no cumplen con raíces fuera del
 ↪círculo unitario

# Iterar sobre cada modelo ajustado en el DataFrame `fitted_models_df`
for index, row in fitted_models_df.iterrows():
    # Obtener el orden del modelo y el objeto del modelo ajustado
    model_order = row['model_order']
    fitted_model = row['fitted_model']

    # Obtener los parámetros MA (Media Móvil) del modelo
```

```python
    ma_params = [param for param in fitted_model.params.index if 'ma.L' in param]
    ma_coefficients = [fitted_model.params[param] for param in ma_params]  # Extraer los valores de los coeficientes MA

    # Calcular las raíces del polinomio MA: 1 - p1*x - p2*x^2 - ...
    ma_roots = np.roots(([1] + [-coeff for coeff in ma_coefficients])[::-1])  # Negar los coeficientes para el cálculo

    # Obtener los parámetros AR (Autoregresivo) del modelo
    ar_params = [param for param in fitted_model.params.index if 'ar.L' in param]
    ar_coefficients = [fitted_model.params[param] for param in ar_params]  # Extraer los valores de los coeficientes AR

    # Calcular las raíces del polinomio AR: 1 - p1*x - p2*x^2 - ...
    ar_roots = np.roots(([1] + [-coeff for coeff in ar_coefficients])[::-1])  # Negar los coeficientes para el cálculo

    # Verificar si todas las raíces están fuera del círculo unitario (valor absoluto > 1)
    if np.all(np.abs(ma_roots) > 1) and np.all(np.abs(ar_roots) > 1):
        admisible_models.append(model_order)  # Agregar el modelo a la lista de modelos admisibles
    else:
        non_admisible_models.append(model_order)  # Agregar el modelo a la lista de modelos no admisibles

# Imprimir los resultados de la prueba
print("\nResumen de la Prueba de Admisibilidad Basada en Raíces de los Polinomios MA y AR:")
print("====================================================")
print("Modelos que Pasaron (Modelos Admisibles con Raíces Fuera del Círculo Unitario):")
print(admisible_models)
print("\nModelos que Fallaron (Modelos No Admisibles con Raíces Dentro o en el Círculo Unitario):")
print(non_admisible_models)
```

```
Resumen de la Prueba de Admisibilidad Basada en Raíces de los Polinomios MA y
AR:
====================================================
Modelos que Pasaron (Modelos Admisibles con Raíces Fuera del Círculo Unitario):
['ARIMA(0,2,0)', 'ARIMA(0,2,2)']

Modelos que Fallaron (Modelos No Admisibles con Raíces Dentro o en el Círculo
```

```
Unitario):
[]
```

0.2.4 Supuesto 7,

verifica si las correlaciones entre los parámetros estimados son pequeñas.

[28]:
```python
from statsmodels.stats.moment_helpers import cov2corr  # Importar función para␣
↪convertir matriz de covarianza a correlación

# Iterar sobre cada modelo ARIMA en el DataFrame `fitted_models_df`
for idx, row in fitted_models_df.iterrows():
    model_name = row['model_order']  # Nombre del modelo (orden ARIMA)
    fitted_model = row['fitted_model']  # Objeto del modelo ajustado

    # Extraer la matriz de varianza-covarianza de los parámetros estimados
    cov_matrix = fitted_model.cov_params()  # Matriz de covarianza de los␣
↪parámetros

    # Convertir la matriz de covarianza a una matriz de correlación
    correlation_matrix = cov2corr(cov_matrix)

    # Crear un DataFrame para hacer la matriz de correlación más legible
    correlation_df = pd.DataFrame(correlation_matrix,
                              index=fitted_model.param_names,  # Usar␣
↪nombres de parámetros como índices
                              columns=fitted_model.param_names)  # Usar␣
↪nombres de parámetros como columnas

    # Mostrar la matriz de correlación
    print(f"\nMatriz de Correlación de Parámetros para {model_name}:")
    print(correlation_df)
```

```
Matriz de Correlación de Parámetros para ARIMA(0,2,0):
        sigma2
sigma2     1.0

Matriz de Correlación de Parámetros para ARIMA(0,2,2):
           ma.L1     ma.L2    sigma2
ma.L1   1.000000 -0.743574 -0.154455
ma.L2  -0.743574  1.000000 -0.032224
sigma2 -0.154455 -0.032224  1.000000
```

0.2.5 Supuesto 8

Verificar si los valores atípicos tienen influencia en el resultado. No es necesario ya que no tenemos valores atípicos.

0.3 Calcular la previsión y los intervalos de confianza

Tomamos el modelo ARIMA(2,2,0) para la predicción, ya que es el único que pasó los 8 supuestos (también tuvo correlaciones pequeñas entre los coeficientes).

[29]:
```python
import matplotlib.pyplot as plt
import pandas as pd
import numpy as np
from scipy import special

# Definir el nivel de confianza para los intervalos
confidence_level = 0.95  # Nivel de confianza del 95%

# Lista de modelos que se usarán para los pronósticos
models_to_forecast = [f'ARIMA(0,{d},2)', f'ARIMA(0,{d},0)']

def forecast(data, models_to_forecast, start, end, lmbda=None):
    """
    Realiza pronósticos para los modelos especificados y compara con los datos␣
 ↪originales.

    Parámetros:
    -----------
    data : pandas.Series
        Serie temporal original.
    models_to_forecast : list
        Lista de nombres de los modelos ARIMA que se utilizarán para el␣
 ↪pronóstico.
    start : int
        Índice inicial del período de pronóstico.
    end : int
        Índice final del período de pronóstico.
    lmbda : float, opcional
        Parámetro de transformación Box-Cox (None si no se aplica).

    Retorno:
    --------
    None. Imprime resultados y genera gráficos.
    """
    forecast_results = {}  # Diccionario para almacenar los resultados de los␣
 ↪pronósticos

    # Recuperar los datos originales para graficar
    data_to_plot = data[start - (end - start) * 2:]  # Incluye un período␣
 ↪adicional para contexto


    # Iterar sobre cada modelo para realizar pronósticos
```

```python
    for model_name in models_to_forecast:
        # Obtener el modelo ajustado del DataFrame
        fitted_model = fitted_models_df.loc[fitted_models_df['model_order'] == model_name, 'fitted_model'].iloc[0]

        # Realizar pronósticos
        forecast = fitted_model.get_prediction(start=start, end=end)
        forecast_mean = forecast.predicted_mean  # Valores pronosticados
        forecast_ci = forecast.conf_int(alpha=1 - confidence_level)  # Intervalos de confianza ajustados

        # Aplicar la transformación inversa de Box-Cox si corresponde
        if lmbda is not None:

            forecast_mean = special.inv_boxcox(forecast_mean, lmbda)


            forecast_ci['lower T_points'] = forecast_ci['lower T_points'].apply(lambda x: special.inv_boxcox(x, lmbda))
            forecast_ci['upper T_points'] = forecast_ci['upper T_points'].apply(lambda x: special.inv_boxcox(x, lmbda))

        # Almacenar los resultados del pronóstico
        forecast_results[model_name] = {'forecast_mean': forecast_mean, 'forecast_ci': forecast_ci}

        # Imprimir los resultados del pronóstico
        print(f"\nPronóstico para {model_name} para los próximos {end - start} períodos con Intervalo de Confianza del {confidence_level * 100:.1f}%:")
        print(forecast_mean)
        print("\nIntervalos de Confianza:")
        print(forecast_ci)

        # Comparar con los datos originales
        print("\nComparación del Pronóstico con los Datos Originales:")
        print("Fecha\t\tPronóstico\tDatos Originales\tDiferencia")
        for i, forecast_value in enumerate(forecast_mean):
            if i in data.index:
                original_value = data.loc[i]
                difference = original_value - forecast_value
                print(f"{i}\t{forecast_value:.2f}\t\t{original_value:.2f}\t\t{difference:.2f}")
            else:
                print(f"{i}\t{forecast_value:.2f}\t\tDatos No Disponibles")
        print("-" * 40)
```

```
    # Generar gráficos de los pronósticos
    plt.figure(figsize=(10, 6))
    plt.plot(data_to_plot.index, data_to_plot, label='Datos Originales',␣
 ↪color='blue')

    colors = plt.rcParams['axes.prop_cycle'].by_key()['color']
    for i, (model_name, result) in enumerate(forecast_results.items()):
        forecast_mean = result['forecast_mean']
        forecast_ci = result['forecast_ci']
        plt.plot(range(start, end+1), forecast_mean, label=f'Pronóstico -␣
 ↪{model_name}', color=colors[i], marker='o')
        plt.fill_between(range(start, end+1), forecast_ci.iloc[:, 0],␣
 ↪forecast_ci.iloc[:, 1], color=colors[i], alpha=0.2)
    #plt.ylim(np.min(data_to_plot)*.7,np.max(data_to_plot)*1.5)
    plt.title(f'Comparación de Pronósticos para {models_to_forecast} con␣
 ↪Intervalo de Confianza del {confidence_level * 100:.1f}%')
    plt.xlabel('Tiempo')
    plt.ylabel('Accesos al Servidor')
    plt.legend()
    plt.grid(True, alpha=0.3)
    plt.tight_layout()
    plt.show()
```

0.3.1 Predecir los valores dentro de la muestra

[30]:
```
# Definir el número de períodos que deseas pronosticar
num_predictions = 10  # Número de períodos a pronosticar

# Determinar el índice del último dato disponible en la serie temporal
end = len(time_series_df['points']) - 1  # Último índice de los datos␣
 ↪disponibles

# Calcular el índice inicial del período a pronosticar
start = end - (num_predictions - 1)  # Comenzar desde los últimos␣
 ↪`num_predictions` períodos

# Llamar a la función forecast para realizar los pronósticos
forecast(
    time_series_df['points'],  # Serie temporal original
    models_to_forecast,        # Lista de modelos ARIMA a utilizar para los␣
 ↪pronósticos
    start=start,               # Índice inicial del período de pronóstico
    end=end,                   # Índice final del período de pronóstico
    lmbda=lmbda                # Parámetro de tran
)
```

```
Pronóstico para ARIMA(0,2,2) para los próximos 9 períodos con Intervalo de
Confianza del 95.0%:
82    59.179097
83    59.627261
84    60.116896
85    61.633527
86    62.747795
87    63.160627
88    63.549805
89    63.963942
90    64.087804
91    64.762458
Name: predicted_mean, dtype: float64

Intervalos de Confianza:
    lower T_points  upper T_points
82       58.533977       59.831327
83       58.977255       60.284430
84       59.461553       60.779461
85       60.961651       62.312807
86       62.063773       63.439357
87       62.472104       63.856739
88       62.857040       64.250206
89       63.266662       64.668907
90       63.389174       64.794134
91       64.056473       65.476224

Comparación del Pronóstico con los Datos Originales:
Fecha           Pronóstico      Datos Originales        Diferencia
0       59.18           30.21           -28.97
1       59.63           30.32           -29.31
2       60.12           30.35           -29.77
3       61.63           30.43           -31.20
4       62.75           30.43           -32.31
5       63.16           30.54           -32.62
6       63.55           30.66           -32.89
7       63.96           30.69           -33.27
8       64.09           30.98           -33.11
9       64.76           31.30           -33.46
----------------------------------------

Pronóstico para ARIMA(0,2,0) para los próximos 9 períodos con Intervalo de
Confianza del 95.0%:
82    59.014541
83    59.537877
84    60.091929
85    61.934301
```

```
86    63.050202
87    63.115974
88    63.379056
89    63.824090
90    63.887010
91    64.711531
Name: predicted_mean, dtype: float64

Intervalos de Confianza:
    lower T_points  upper T_points
82       58.278443       59.759937
83       58.795251       60.289883
84       59.342392       60.850933
85       61.161784       62.716576
86       62.263766       63.846572
87       62.328718       63.913174
88       62.588518       64.179579
89       63.028001       64.630234
90       63.090137       64.693949
91       63.904373       65.528884

Comparación del Pronóstico con los Datos Originales:
Fecha           Pronóstico      Datos Originales        Diferencia
0       59.01           30.21           -28.80
1       59.54           30.32           -29.22
2       60.09           30.35           -29.74
3       61.93           30.43           -31.50
4       63.05           30.43           -32.62
5       63.12           30.54           -32.58
6       63.38           30.66           -32.72
7       63.82           30.69           -33.13
8       63.89           30.98           -32.91
9       64.71           31.30           -33.41
----------------------------------------
```

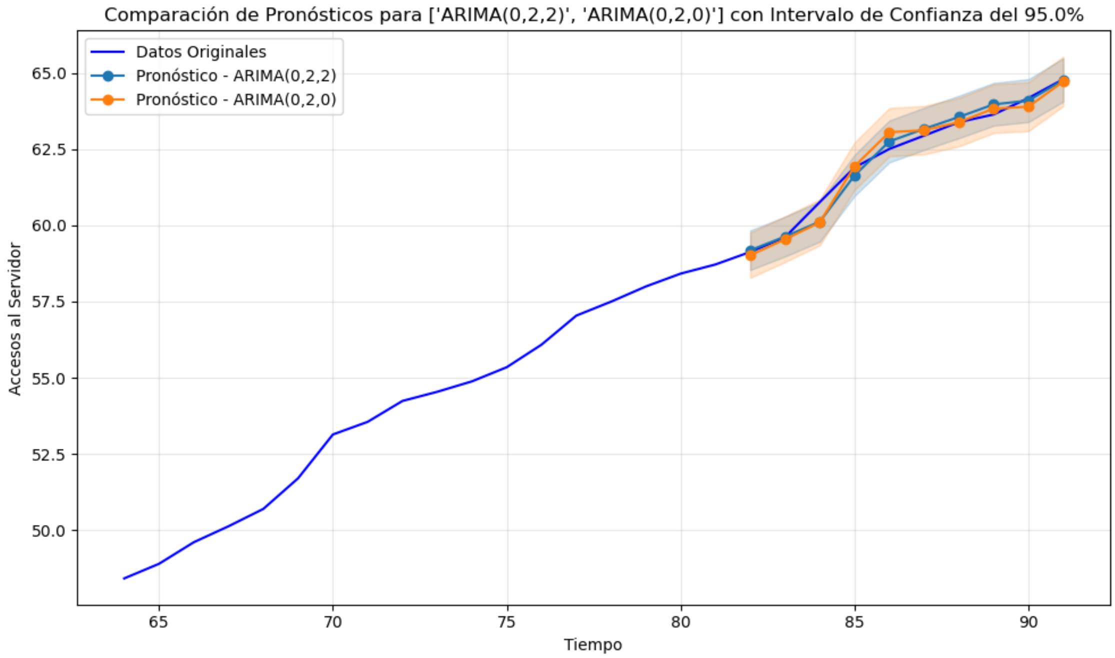

0.3.2 Predecir los valores fuera de la muestra

[31]:
```
# Definir el número de períodos que deseas pronosticar hacia el futuro
num_predictions = 10  # Número de períodos a pronosticar

# Calcular el índice de inicio y final para los pronósticos futuros
start = len(time_series_df['points'])  # Índice inmediatamente después de los␣
↪datos disponibles
end = start + num_predictions - 1  # Índice final de los pronósticos (10␣
↪períodos hacia el futuro)

# Llamar a la función forecast para realizar los pronósticos
forecast(
    time_series_df['points'],  # Serie temporal original
    models_to_forecast,        # Lista de modelos ARIMA a utilizar para los␣
↪pronósticos
    start=start,               # Índice inicial del período de pronóstico␣
↪(futuro)
    end=end,                   # Índice final del período de pronóstico (futuro)
    lmbda=lmbda                # Parámetro de transformación Box-Cox (si se␣
↪aplicó previamente)
)
```

Pronóstico para ARIMA(0,2,2) para los próximos 9 períodos con Intervalo de Confianza del 95.0%:

```
92     65.375971
93     65.963622
94     66.556554
95     67.154816
96     67.758456
97     68.367522
98     68.982063
99     69.602127
100    70.227766
101    70.859027
Name: predicted_mean, dtype: float64

Intervalos de Confianza:
     lower T_points  upper T_points
92        64.663299       66.096499
93        64.653542       67.300247
94        64.710680       68.455082
95        64.773941       69.623205
96        64.827575       70.821844
97        64.865579       72.058528
98        64.885359       73.337423
99        64.885796       74.661273
100       64.866495       76.032150
101       64.827441       77.451797

Comparación del Pronóstico con los Datos Originales:
Fecha          Pronóstico      Datos Originales        Diferencia
0       65.38           30.21           -35.17
1       65.96           30.32           -35.64
2       66.56           30.35           -36.21
3       67.15           30.43           -36.72
4       67.76           30.43           -37.33
5       68.37           30.54           -37.83
6       68.98           30.66           -38.33
7       69.60           30.69           -38.91
8       70.23           30.98           -39.25
9       70.86           31.30           -39.56
----------------------------------------

Pronóstico para ARIMA(0,2,0) para los próximos 9 períodos con Intervalo de
Confianza del 95.0%:
92     65.409932
93     66.038854
94     66.673823
95     67.314897
96     67.962136
97     68.615597
98     69.275342
```

```
99     69.941430
100    70.613922
101    71.292881
Name: predicted_mean, dtype: float64

Intervalos de Confianza:
     lower T_points  upper T_points
92        64.594063       66.236107
93        64.211163       67.918569
94        63.614964       69.879764
95        62.842639       72.105428
96        61.921401       74.592174
97        60.872751       77.343312
98        59.714628       80.366790
99        58.462536       83.674160
100       57.130193       87.280049
101       55.729926       91.201895

Comparación del Pronóstico con los Datos Originales:
Fecha           Pronóstico      Datos Originales        Diferencia
0       65.41           30.21           -35.20
1       66.04           30.32           -35.72
2       66.67           30.35           -36.32
3       67.31           30.43           -36.88
4       67.96           30.43           -37.53
5       68.62           30.54           -38.08
6       69.28           30.66           -38.62
7       69.94           30.69           -39.25
8       70.61           30.98           -39.64
9       71.29           31.30           -39.99
----------------------------------------
```

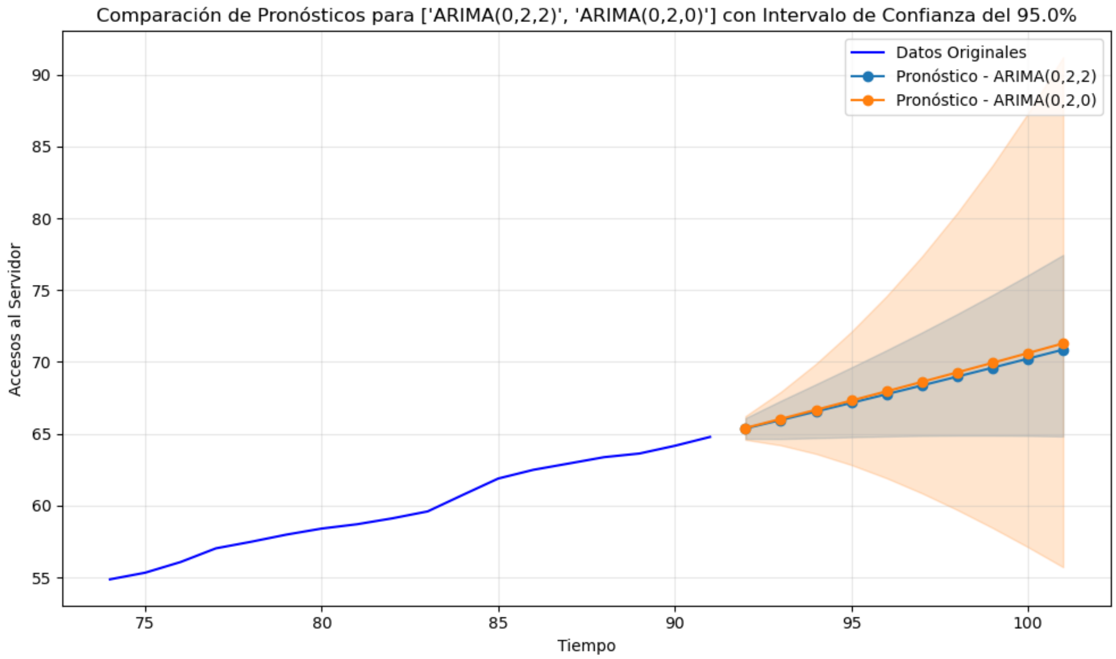
Comparación de Pronósticos para ['ARIMA(0,2,2)', 'ARIMA(0,2,0)'] con Intervalo de Confianza del 95.0%
Datos Originales
Pronóstico - ARIMA(0,2,2)
Pronóstico - ARIMA(0,2,0)
Accesos al Servidor
Tiempo
90
85
80
75
70
65
60
55
75
80
85
90
95
100

[ ]: